

RPG의 동적 PVE 콘텐츠를 위한 강화학습 에이전트의 설계 및 적응에 관한 연구

최성우, 조명아
경희대학교 소프트웨어융합학과
vactor823@khu.ac.kr, maycho@khu.ac.kr

A Study on the Design and Adaptation of a Reinforcement Learning Agent for Dynamic PVE Contents in RPG

SungWoo Choi, MyeongAh Cho
Department of Software Convergence, Kyung Hee University
vactor823@khu.ac.kr, maycho@khu.ac.kr

요약

기존 RPG 장르 비디오 게임의 PVE 콘텐츠에서 사용되는 AI는 예측 가능한 스크립트 기반 행동 패턴으로 인해 플레이어의 경험을 제한하는 경우가 많다. 본 연구는 이러한 한계를 극복하기 위해 Unity ML-Agents 환경에서 강화학습 알고리즘 PPO를 사용하여, 이동하는 타겟을 추적하고 근접 공격을 수행하는 AI를 개발하는 것을 목표로 한다. 복합 행동 시 발생하는 불안정성 문제를 해결하기 위해, 본 연구는 모듈식 학습 전략을 제안한다. 실험 결과, 제안하는 학습 방식은 모든 행동을 동시에 학습시키는 통합 학습 방식에 비해 학습 안정성과 성능 측면에서 우수성을 보였다. 본 연구는 이를 통해 게임 AI 행동 설계에 있어 강화학습의 적용 방법론을 제시한다.

1. 서론

기존 RPG의 PVE 콘텐츠는 대부분 스크립트 기반의 AI를 사용하여 패턴이 고정적이고 예측 가능함으로써 반복적으로 플레이할 경우, 플레이어의 몰입도와 전략적 깊이를 저해하는 한계를 갖는다. 본 연구는 이러한 문제를 극복하기 위해 강화학습을 도입하여 예측 불가능하고 도전적인 경험을 제공하는 AI 에이전트 개발을 목표로 한다. 이를 위해 Unity ML-Agents 환경에서 이동 및 전투 AI를 구현하며, 특히 복합 행동을 학습하는 과정에서 발생하는 불안정성을 해결하기 위한 효율적인 학습 방법론을 제안한다.

2. 선행 연구

강화학습은 다양한 게임 환경에서 우수한 성능을 보여주며 게임 AI 개발의 새로운 가능성을 제시했다. 그러나 강화학습을 실제 복잡한 게임 환경에 직접 적용하는 것은 여전히 도전적인 과제이다.

2.1 계층적 강화학습 및 모듈화 접근

복잡한 행동을 유도하기 위한 하나의 접근법으로 계층적 강화학습(HRL)이 연구됐다. HRL은 태스크(Task)를 여러 하위 목표로 분리하고, 각 목표를 담당하는 하위 정책들을 상위 정책이 관리하는 구조를 통해 이를 해결하고자 한다. 그러나 HRL 프레임워크를 실제 게임 환경에 적용하는 것은 여전히 도전적인 과제이며, 각 계층 간 효과적인 목표 설정을 설정하는 것 또한 복잡

하다. 본 연구는 HRL의 핵심 개념인 ‘모듈 분할’과 ‘선행 학습’ 개념을 차용하되, Unity ML-Agents 환경에 맞춘 시스템과 지식 전이 명령어를 활용한 모듈식 학습 방법을 적용하였다.

3. 제안 방법

복합적인 행동을 단일 정책으로 처음부터 학습시키는 통합 학습 방식은 높은 탐색 복잡성과 희소한 보상 신호로 인해 학습 불안정성 또는 의도하지 않은 행동의 수렴 문제를 야기하기 쉽다. 이러한 문제를 해결하기 위해, 본 연구는 다음과 같은 요소를 결합한 훈련 프레임워크를 제안한다.

3.1 정교한 보상 설계

본 연구에서는 효율적인 근접 전투 AI학습을 위해 정교한 복합 보상 함수를 설계하였다. 기본적으로 타겟과의 거리가 가까워지면 보상을 주되, 방향 정렬 보상과 속도 보상을 추가하여 AI가 타겟을 정면으로 바라보고 그 방향으로 전진하도록 유도하였다. 동시에, 타겟 주위를 맴돌거나, 제자리에서 진동하는 등 비효율적인 움직임을 감지하여 페널티를 부과함으로써 학습 안정성을 확보하였다. 또한, 공격 행동 자체에 비용을 부과하고, 타격 정확도에 따라 보상을 차등 지급하여 AI가 공격을 난사하지 않고 정확한 타이밍을 학습하도록 유도하였다. 이 외에 벽 충돌 및 시간 경과 등 기본적인 환경 페널티를 포함시켰다.

3.2 모듈식 학습 전략

통합 학습의 불안정성을 완화하기 위해, 계층적 강화학습의 문제 분할 개념에서 착안하여 보스 AI 행동을 분리한 후 단계적으로 학습시키는 모듈식 접근법을 채택하였다. 본 연구에서는 Unity 에이전트 스크립트 내 열거형

변수를 활용하여 학습 단계를 명시적으로 구분하고, 각 단계별로 활성화되는 보상 함수와 행동 공간을 제어하는 방식으로 구현하였다.

먼저, 안정적인 이동 모듈을 구축하기 위해 Behavior Parameters에서 이산 행동 공간의 크기를 0으로 지정하여 공격 능력을 신경망 구조 수준에서 원천적으로 배제하였다. 이후 공격 행동 학습 단계에서 Discrete Actions 크기를 확장하였고, ML-Agents의 지식 전이 기능인 --initialize-from 명령어를 사용하여 이전 단계에서 학습된 이동 모듈의 가중치를 초기값으로 활용하였다. 이 방식을 통해 AI가 이미 학습된 이동 능력을 바탕으로 추가된 공격 행동과의 통합적 판단 학습에만 집중하도록 유도함으로써, 기존 학습 내용의 손실(catastrophic forgetting)을 방지하고 전체 학습 과정을 안정화시키는 효과를 가져왔다.

4. 실험

제안하는 모듈식 학습 방법의 유효성을 검증하기 위해, 통합 학습 방법 및 다른 강화 학습 알고리즘(SAC)을 비교군으로 설정하여 실험을 진행하였다. 실험 결과의 통계적 유의성을 확보하기 위해 서로 다른 2개의 시드에서 반복 수행하였고, 그 결과는 평균 및 표준편차로 제시하였다.

4.1 실험 환경

Unity Version : Unity 2022.3.62f1

ML-Agents Version : 2.0.1

Communicator API : 1.5.0

PyTorch : 1.10.0 / CUDA 11.3

Hardware : GPU(NVIDIA Geforce RTX 4050 6GB), RAM 16GB

4.2 학습 설정

PPO 알고리즘을 사용한 실험에서 주요 하이퍼파라미터는 설정은 다음과 같다.

Hyperparameters:

batch_size : 2048

buffer_size : 20480

learning_rate : 1.0e-4

beta : 5.0e-3

lambda : 0.95

num_epoch : 3

Network Settings:

hidden_units : 512

num_layers : 3

Reward Signals:

gamma : 0.99

SAC 알고리즘을 사용한 실험에서 주요 하이퍼파라미터 설정은 다음과 같다.

Hyperparameters:

batch_size : 256

buffer_size : 50000

learning_rate : 1.0e-4

tau : 0.005

init_entcoef : 0.5

4.3 비교 실험 설계

세 실험군은 동일한 에이전트 구조 및 관측 공간을 사용하였고, 동일한 학습 환경 및 하이퍼파라미터에서 훈련되었다. 공격 학습에 사용한 타겟은 속도 1.0으로 30x30 정사각형 크기의 아레나 범위 내에서 랜덤으로 움직이도록 하였다.

1) 비교군 1 : 처음부터 모든 행동(이동, 공격)을 동시에 학습시킨 모델로 Discrete Actions의 크기를 1로 설정한 후 PPO 알고리즘으로 학습시켰다. 통합 환경에서 300만 스텝 학습시켰다.

2) 비교군 2 : 알고리즘에 따른 성능 차이를 검증하기 위해, SAC 알고리즘을 사용하여 동일한 통합 환경에서 300만 스텝 학습시켰다. 단, SAC 알고리즘의 경우 행동-가치 함수가 상태와 행동을 모두 입력으로 받는 형태를 가진다. 본 연구의 모듈식 학습에서는 행동 공간의 차원 변화가 발생하는데, 이로 인해 SAC의 네트워크 입력 차원이 불일치하게 되어 사전 학습된 모델의 가중치를 전이하는 것이 불가능하였다. 따라서 SAC는 모듈식 학습 방법을 제외하고, 통합 학습 방식에 대해서 실험을 수행하였다.


3) 모듈식 학습 : 4장에서 기술한 바와 같이 Discrete Actions 크기를 0으로 설정하여 이동 모듈을 먼저 학습시킨 후 전이 학습 명령어로 불러와 공격 행동과 결합시킨 모델이다. 이동 학습 150만 스텝 이후, 공격 학습 150만 스텝 진행하였다.

4.4 학습 안정성 평가


1) 누적 보상 : 학습 진행에 따른 에이전트의 평균적인 성능 변화 추이로, 더 높고 안정적으로 수렴할수록 우수한 학습이 이루어졌다고 판단했다.


2) 가치 손실 : 에이전트의 가치 예측 정확도로, 더 낮고 안정적으로 수렴할수록 학습 안정성이 높다고 판단했다.

[표 1 - 비교군 1의 평가 지표 그래프]




[표 2 - 비교군 2의 평가 지표 그래프]





[표 3 - 모듈식 학습 모델의 공격 학습 평가 지표 그래프]



학습 곡선 분석 결과, 모듈식 학습 방식은 학습 초기부터 안정적이고 우수한 성능을 보였다. 반면에, 통합 학습 방식은 알고리즘에 따라 상이한 양상의 한계를 보였다. PPO 통합 학습은 학습 초기 탐색 공간이 너무 넓어 최적의 정책을 찾는 것에 어려움을 겪었으며, 공격을 포기하고 이동에만 집중하는 현상이 관찰되었다. SAC 통합 학습은 초반에는 빠른 보상 상승을 보였으나, PPO대비 약 1.6배의 긴 학습 소요 시간이 소요되었음에도 불구하고, 복잡한 행동 공간에서 적절한 정책 유지에 실패하며 급격한 성능 저하와 심하게 진동하는 모습을 보였다. Value Loss 측면에서도 오히려 증가하는 경향을 보였는데, 이는 단일 정책으로는 복잡한 상태-행동 공간에 대한 가치 추정이 실패하였음을 시사한다. 결과적으로 본 실험은 알고리즘 종류와 투입된 연산 시간과 무관하게, 복잡한 과제 해결을 위해서는 단계적 접근법이 필수적임을 입증한다.

4.5 정량적 비교 분석

세 학습 방식으로 최종 훈련된 모델의 정량적 성능을 비교하고 평가하기 위해 다음과 같은 절차를 수행하였다. 학습된 .onnx 파일을 에이전트 컴포넌트에 적용하고, 행동 타입을 Inference Only로 설정하였다. 평가 환경은 학습 환경과 동일하게 유지하였으며 각 모델에 대해 1분으로 제한한 에피소드를 총 100회 시행하였다. 각 에피소드가 진행되는 동안 타겟과 일정 범위(3.0f) 내에서 거리를 유지한 시간, 공격 시도 횟수, 공격 성공 횟수, 벽 충돌 횟수와 같은 데이터를 수집하였고, 100회의 에피소드가 종료된 후, 수집된 데이터를 바탕으로 각 모델에 대한 평균 성능 지표를 산출하여 분석하였다.

1) 비교 결과

최종 모델 성능을 정량적으로 비교한 결과는 다음과 같다. 모든 성능 지표는 2개의 모델 시드를 각각 평가한 후 산출된 평균값이다.

평가 지표	비교군 1	비교군 2	제안 방식	단위
타겟과의 일정 범위 유지 시간	31.1	2.7	96.1	%
에피소드 당 공격 시도 횟수	1.65	0.0	16.57	회
공격 성공률	15.0	0.0	95.9	%
벽 충돌 횟수	9.19	0.12	14.81	회

2) 결과 분석

SAC 통합 모델 : 일정 범위 유지 비율과 공격 시도가 모두 0회에 수렴하였다. 이는 SAC 알고리즘이 복잡한 상태 공간에서 유의미한 정책 학습을 하지 못하고, 무의미한 행동을 반복하는 상태로 붕괴되었음을 보여준다.

PPO 통합 모델 : 공격 시도 횟수가 매우 낮고, 성공률 또한 저조했다. 타겟과의 거리 유지에도 실패하였다.

모듈식 학습 모델 : 타겟과의 거리 유지 비율 96.1%를 기록하며, 타겟과의 거리를 제어하는 모습을 보였고, 평균 16.57회의 적극적인 공격을 시도하면서도 95.9%라는 높은 공격 성공률을 달성하였다. 이는 에이전트가 고도의 전략을 성공적으로 학습하였음을 증명한다. 제안된 학습 모델이 벽 충돌 횟수가 높게 나타난 것은 좁은 공간 내에서 타겟을 상대로 끊임없이 거리를 유지하기 위해 기동했기 때문이라고 분석된다. 제안 모델의 충돌은 적극적인 교전을 위한 기회 비용으로 해석할 수 있다.

5. 결론

본 연구는 RPG PVE 콘텐츠에서 기존 스크립트 기반 AI의 예측 가능성 문제를 해결하기 위해 Unity ML-Agents 환경에서 모듈식 학습 전략과 정교한 보상 설계를 결합한 강화학습 프레임워크를 제안하였다. 실험을 통해 제안한 모듈식 학습법이 복잡한 행동을 동시에 학습시키는 통합 방식보다 우수한 성능을 보임을 확인하였으며, 이는 태스크를 하위 모듈로 분리하고 명확한 보상을 설계하는 전략이 게임 AI 개발에 효과적임을 입증한다. 본 연구는 이동과 공격에 초점을 맞추었으나, 향후 연구에서는 다중 행동 모듈로 확장하고, 개발된 AI를 전통적인 패턴 기반 AI와 비교하여 실제 플레이어 UX에 긍정적인 영향을 미치는지 검증함으로써 차세대 게임 콘텐츠 개발 연구로 발전시킬 수 있을 것이다.

참고 문헌

- [1] Andrew Y. NG, Daishi Harada, Stuart J. Russell, "Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping, ICML '99: Proceedings of the Sixteenth International Conference on Machine Learning, pp 278 - 287, 1999
- [2] Young Ho Lee, "Implementation of Intelligent Agent Based on Reinforcement Learning Using Unity ML-Agents", The Journal of The Institute of Internet, Broadcasting and Communication (IIBC) Vol. 24, No. 2, pp.205-211, 2024
- [3] Qingyu Xiao, Yuanlin Chang, Youtian Du, "Decoupled Hierarchical Reinforcement Learning With State Abstraction for Discrete Grids", arXiv, 2025